

LL128

NCCL defaults: 10,054

9,561

T256 C16 M2 R1 S1 G2
T160 C4 M2 R1 S1 G2
T64 C16 M2 R1 S1 G2
T160 C16 M2 R1 S1 G2
T256 C4 M2 R1 S1 G2
T64 C8 M2 R1 S1 G2
T64 C4 M2 R1 S1 G2
T256 C8 M2 R1 S1 G2
T160 C8 M2 R1 S1 G2

Simple

8,251

T256 C8 M2 R1 S1 G2
T256 C4 M2 R1 S1 G2
T256 C16 M2 R1 S1 G2
T160 C4 M2 R1 S1 G2
T160 C8 M2 R1 S1 G2
T160 C16 M2 R1 S1 G2
T64 C16 M2 R1 S1 G2
T64 C4 M2 R1 S1 G2
T64 C8 M2 R1 S1 G2

LL

6,475

T256 C16 M2 R1 S1 G2
T256 C8 M2 R1 S1 G2
T256 C4 M2 R1 S1 G2
T160 C8 M2 R1 S1 G2
T160 C4 M2 R1 S1 G2
T160 C16 M2 R1 S1 G2
T64 C4 M2 R1 S1 G2
T64 C4 M1 R1 S1 G2
T64 C4 M2 R0 S1 G2
T64 C4 M1 R1 S2 G2
T64 C4 M1 R0 S2 G2
T64 C4 M1 R0 S1 G2
T64 C4 M8 R1 S1 G2
T64 C16 M2 R1 S1 G2
T64 C4 M2 R1 S1 G2
T64 C8 M2 R1 S1 G2
T64 C4 M1 R1 S2 G0
T64 C4 M1 R0 S2 G0
T64 C4 M1 R0 S1 G0
T64 C4 M1 R1 S1 G0
T64 C4 M2 R0 S1 G0



GPU-Direct RDMA disabled (G=0)

0 2000 4000 6000 8000 10000

Total token throughput (tok/s)